

# ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ

## ΕΡΓΑΣΙΑ 2<sup>Η</sup> ΑΚΑΔΗΜΑΙΚΟ ΕΤΟΣ : 2018-2019

ΦΟΙΤΗΤΗΣ: ΙΑΚΩΒΟΣ ΕΥΔΑΙΜΩΝ 3130059

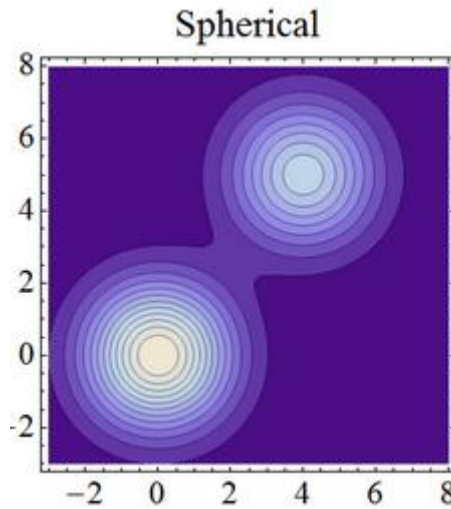
Η εργασία αυτή επικεντρώνεται στην υλοποίηση του αλγορίθμου EM(expectation maximization) για την μεγιστοποίηση της πιθανοφάνειας σε μία μίξη Gaussian κατανομών της παρακάτω μορφής:

$$\begin{aligned} p(\mathbf{x}) &= \sum_{k=1}^K \pi_k \prod_{d=1}^D \frac{1}{\sqrt{2\pi\sigma_k^2}} e^{-\frac{1}{2\sigma_k^2}(x_d - \mu_{kd})^2} = \\ &= \sum_{k=1}^K \pi_k \prod_{d=1}^D N(x_d | \mu_{kd}, \sigma_k^2) \end{aligned}$$

$$\text{Όπου } N(x_d | \mu_{kd}, \sigma_k^2) = \frac{1}{\sqrt{2\pi\sigma_k^2}} e^{-\frac{1}{2\sigma_k^2}(x_d - \mu_{kd})^2} \text{ εδ\omega.}$$

Σε αυτή την εργασία θα επεξεργαστούμε εικόνες όπου ισχύει ότι κάθε δεδομένο είναι ένα pixel και συγκεκριμένα ένα 3-διάστατο διάνυσμα  $\mathbf{x}_n = [x_r, x_g, x_b]$  όπου  $x_r, x_g, x_b$  είναι οι τρεις τιμές για το εκάστοτε κανάλι χρώματος.

Από τον τύπο της παραπάνω μίξης κατανομών διαπιστώνουμε ότι οι συνιστώσες κάθε  $\mathbf{x}_n$  διανύσματος (δεδομένου/εδ\ω pixel) είναι ανεξάρτητες, δηλαδή για την εργασία μας τα κανάλια RGB κάθε pixel. Οι παραπάνω Gaussian συνιστώσες κατανομές έχουν πίνακα συμμεταβλητότητας/συνδιακύμανσης (covariance matrix) σφαιρικό, που σημαίνει ότι έχει όλες τις εκτός διαγωνίου καταχωρήσεις ίσες με μηδέν. Από κάτω παραθέτεται η εικόνα με την μορφή των σφαιρικών συνδιακυμάνσεων.



Έχουμε την υπόθεση ότι έχουμε μία τυχαία μεταβλητή  $z$ , η οποία επιλέγεται με βάση τις πιθανότητες  $\pi_k$  και ουσιαστικά ταυτοποιεί την ομάδα  $k$  της οποίας θα είναι μέλος κάθε δεδομένο  $x_n$  που θα παραχθεί. Έτσι έχουμε μία  $K$ -διαστάσεων ( $K = \text{αριθμός ομάδων}$ ) δυαδική τυχαία μεταβλητή  $z$  και σε μία αναπαράσταση 1-του- $K$  στην οποία ένα στοιχείο  $z_k = 1$  και όλα τα άλλα ίσα με μηδέν. Οπότε, υπάρχουν  $K$  πιθανές καταστάσεις για το διάνυσμα  $z$  ώστε ένα στοιχείο να είναι μη-μηδενικό. Άρα  $z_k \in \{0, 1\}$  και  $\sum_k z_k = 1$ . Ουσιαστικά η πιθανότητα ενός στοιχείου  $z_k = 1$  είναι ίση με το  $\pi_k$  το οποίο συμβολίζει την εκ των προτέρων πιθανότητα της ομάδας  $k$ .

$$p(z_k = 1) = \pi_k$$

$$\text{και } \sum_{k=1}^K \pi_k = 1 \text{ και } 0 \leq \pi_k \leq 1$$

Το πιθανοτικό μοντέλο ομαδοποίησης ( $k$  ομάδων) υποθέτει ότι κάθε δεδομένο παράγεται από τις εξής συνθήκες. Καθορίζεται η ομάδα από την οποία θα παραχθεί το δεδομένο δηλαδή καθορίζεται η τιμή της τυχαίας μεταβλητής  $z$ .

$$p(z) = \prod_{k=1}^K \pi_k^{z_k} \quad (1.1)$$

Και καθορίζεται η παραγωγή του δεδομένου δοθέντος του  $z$  (θεωρούμε ότι οι διαστάσεις του δεδομένου είναι υπό συνθήκη ανεξάρτητες):

$$p(x|z_k = 1) = \prod_{d=1}^D \mathcal{N}(x_d | \mu_{kd}, \sigma_k^2) \quad (1.2)$$

Το οποίο μπορεί να γραφτεί και στην μορφή:

$$p(x|z) = \prod_{k=1}^K \prod_{d=1}^D \mathcal{N}(x_d | \mu_{kd}, \sigma_k^2)^{z_k}$$

Από τις εξισώσεις (1.1) και (1.2) ορίζουμε την ολική κατανομή του  $X$ /μίξη κατανομών η οποία υπολογίζεται εφαρμόζοντας τον κανόνα του αθροίσματος και περιθωριοποιώντας τον άγνωστο  $z$  και είναι ίδια με τον τύπο της εκφώνησης, επιβεβαιώνοντάς την.

$$p(x) = \sum_z p(z)p(x|z) = \sum_{k=1}^K \pi_k \prod_{d=1}^D \mathcal{N}(x_d | \mu_{kd}, \sigma_k^2)$$

$$\text{και } \sum_{k=1}^K \pi_k = 1 \text{ και } 0 \leq \pi_k \leq 1$$

Όπου οι παράμετροι του μοντέλου που πρέπει να εκτιμήσουμε είναι οι:  $\{\pi_k, \mu_{kd}, \sigma_k^2\}_{k=1}^K$

Έστω ότι υπολογίσαμε τις παραπάνω παραμέτρους θα πρέπει επίσης να εισάγουμε και ένα συμπέρασμα για την άγνωστη τυχαία/κρυμμένη μεταβλητή  $z$  για αυτό το λόγο πρέπει να υπολογίσουμε την υπό συνθήκη πιθανότητα του  $z$  δοθέντος του  $x$  χρησιμοποιώντας το θεώρημα του Bayes

$$\gamma(z_k) = p(z_k = 1|x) = \frac{p(x|z_k = 1)p(z_k=1)}{p(x)} =$$

$$\frac{\pi_k \prod_{d=1}^D \mathcal{N}(x_d | \mu_{kd}, \sigma_k^2)}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_d | \mu_{jd}, \sigma_j^2)}$$

$$\text{και } \gamma(z_{nk}) = \frac{\pi_k \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2)}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{jd}, \sigma_j^2)}$$

$X = \{x_1, x_2, x_3, \dots, x_N\}$  δηλαδή αποτελεί όλα τα παραδείγματα  $x_n$  που έχουμε, δηλαδή το  $X$  είναι το σύνολο των παραδειγμάτων εκπαίδευσης, όπου κάθε  $x_n = \{x_{n1}, x_{n2}, \dots, x_{nK}\}$  έχει παραχθεί ανεξάρτητα από την μίξη.

Οπότε η από κοινού κατανομή που έχουμε είναι η εξής:

$$p(X|\pi, \mu, \sigma^2) = \prod_{n=1}^N \sum_{k=1}^K \pi_k \prod_{d=1}^D \mathcal{N}(x_{nd}|\mu_{kd}, \sigma_k^2)$$

και η λογαριθμική πιθανοφάνεια η εξής:

$$\mathcal{L}(\pi, \mu, \sigma^2) = \sum_{n=1}^N \log \sum_{k=1}^K \pi_k \prod_{d=1}^D \mathcal{N}(x_{nd}|\mu_{kd}, \sigma_k^2)$$

Για την εκτίμηση των παραμέτρων  $\{\pi_k, \mu_{kd}, \sigma_k^2\}_{k=1}^K$  πρέπει να μεγιστοποιήσουμε την λογαριθμική πιθανοφάνεια ως προς κάθε μία από τις παραμέτρους που ψάχνουμε. Η μεγιστοποίηση γίνεται με την βοήθεια του αλγορίθμου EM.

Αρχικά μεγιστοποιούμε την  $\mathcal{L}(\pi, \mu, \sigma^2)$  ως προς την παράμετρο  $\mu_{kd}$  (μέση τιμή κάθε Γκαουσιανής κατανομής) και εργαζόμαστε ως εξής:

$$\begin{aligned} \frac{\partial \mathcal{L}(\pi, \mu, \sigma^2)}{\partial \mu_{kd}} &= \\ &= \sum_{n=1}^N \frac{1}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd}|\mu_{jd}, \sigma_j^2)} \frac{\partial (\sum_{k=1}^K \pi_k \prod_{d=1}^D \mathcal{N}(x_{nd}|\mu_{kd}, \sigma_k^2))}{\partial \mu_{kd}} \\ &= \sum_{n=1}^N \frac{1}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd}|\mu_{jd}, \sigma_j^2)} \pi_k \frac{\partial (\prod_{d=1}^D \mathcal{N}(x_{nd}|\mu_{kd}, \sigma_k^2))}{\partial \mu_{kd}} \quad (1) \end{aligned}$$

Όπου, το:

$$\begin{aligned}
& \frac{\partial(\prod_{d=1}^D \mathcal{N}(x_{nd}|\mu_{kd}, \sigma_k^2))}{\partial \mu_{kd}} = \\
&= \prod_{m=1}^{d-1} \mathcal{N}(x_{nm}|\mu_{km}, \sigma_k^2) \prod_{p=d+1}^D \mathcal{N}(x_{np}|\mu_{kp}, \sigma_k^2) \frac{\partial(\mathcal{N}(x_{nd}|\mu_{kd}, \sigma_k^2))}{\partial \mu_{kd}} \\
&= \prod_{m=1}^{d-1} \mathcal{N}(x_{nm}|\mu_{km}, \sigma_k^2) \prod_{p=d+1}^D \mathcal{N}(x_{np}|\mu_{kp}, \sigma_k^2) \frac{\partial\left(\frac{1}{\sqrt{2\pi}\sigma_k^2} e^{-\frac{1}{2\sigma_k^2}(x_{nd}-\mu_{kd})^2}\right)}{\partial \mu_{kd}} \\
&= \prod_{m=1}^{d-1} \mathcal{N}(x_{nm}|\mu_{km}, \sigma_k^2) \prod_{p=d+1}^D \mathcal{N}(x_{np}|\mu_{kp}, \sigma_k^2) \frac{1}{\sqrt{2\pi}\sigma_k^2} e^{-\frac{1}{2\sigma_k^2}(x_{nd}-\mu_{kd})^2} \\
&\quad \frac{\partial\left(-\frac{1}{2\sigma_k^2}(x_{nd}-\mu_{kd})^2\right)}{\partial \mu_{kd}} = \mathcal{N}(x_{nd}|\mu_{kd}, \sigma_k^2) \prod_{m=1}^{d-1} (\mathcal{N}(x_{nm}|\mu_{km}, \sigma_k^2)) \\
&\quad \prod_{p=d+1}^D (\mathcal{N}(x_{np}|\mu_{kp}, \sigma_k^2)) \frac{\partial(-\frac{1}{2\sigma_k^2}(x_{nd}-\mu_{kd})^2)}{\partial \mu_{kd}} = \\
&= \left(\prod_{d=1}^D (\mathcal{N}(x_{nd}|\mu_{kd}, \sigma_k^2))\right) \frac{1}{\sigma_k^2} (x_{nd} - \mu_{kd}) (2)
\end{aligned}$$

Εφαρμόζοντας την σχέση (2) στην (1) και το γεγονός ότι

$$\gamma(z_{nk}) = \frac{\pi_k \prod_{d=1}^D \mathcal{N}(x_{nd}|\mu_{kd}, \sigma_k^2)}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd}|\mu_{jd}, \sigma_j^2)} \text{ τότε καταλήγουμε ότι:}$$

$$\begin{aligned}
(1) &\stackrel{(2)}{\Rightarrow} \sum_{n=1}^N \frac{\pi_k \prod_{d=1}^D \mathcal{N}(x_{nd}|\mu_{kd}, \sigma_k^2)}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd}|\mu_{jd}, \sigma_j^2)} \frac{1}{\sigma_k^2} (x_{nd} - \mu_{kd}) = \\
&= \sum_{n=1}^N \gamma(z_{nk}) \frac{1}{\sigma_k^2} (x_{nd} - \mu_{kd})
\end{aligned}$$

και αφού θέλουμε  $\frac{\partial \mathcal{L}(\pi, \mu, \sigma^2)}{\partial \mu_{kd}} = 0 \Rightarrow$

$$\sum_{n=1}^N \gamma(z_{nk}) \frac{1}{\sigma_k^2} (x_{nd} - \mu_{kd}) = 0 \Rightarrow$$

$$\sum_{n=1}^N \gamma(z_{nk}) (x_{nd} - \mu_{kd}) = 0 \Rightarrow$$

$$\sum_{n=1}^N \gamma(z_{nk}) x_{nd} = \sum_{n=1}^N \gamma(z_{nk}) \mu_{kd} \Rightarrow$$

$$(\mu_{kd})^{new} = \frac{\sum_{n=1}^N \gamma(z_{nk}) x_{nd}}{\sum_{n=1}^N \gamma(z_{nk})}$$

Και αυτός είναι ο τελικός μας τύπος για την ενημέρωση της παραμέτρου  $\mu_{kd}$ .

Έπειτα, μεγιστοποιούμε την  $\mathcal{L}(\pi, \mu, \sigma^2)$  ως προς την παράμετρο  $\sigma_k^2$  (διακύμανση κάθε Γκαουσιανής κατανομής) και εργαζόμαστε ως εξής:

$$\begin{aligned} \frac{\partial \mathcal{L}(\pi, \mu, \sigma^2)}{\partial \sigma_k^2} &= \\ &= \sum_{n=1}^N \frac{1}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{jd}, \sigma_j^2)} \frac{\partial (\sum_{k=1}^K \pi_k \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2))}{\partial \sigma_k^2} \\ &= \sum_{n=1}^N \frac{1}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{jd}, \sigma_j^2)} \pi_k \frac{\partial (\prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2))}{\partial \sigma_k^2} \quad (3) \end{aligned}$$

Όπου, το:

$$\begin{aligned}
& \frac{\partial(\prod_{d=1}^D \mathcal{N}(x_{nd}|\mu_{kd}, \sigma_k^2))}{\partial \sigma_k^2} = \\
& = \sum_{d=1}^D \left( \prod_{m=1}^{d-1} \mathcal{N}(x_{nm}|\mu_{km}, \sigma_k^2) \prod_{p=d+1}^D \mathcal{N}(x_{np}|\mu_{kp}, \sigma_k^2) \frac{\partial(\mathcal{N}(x_{nd}|\mu_{kd}, \sigma_k^2))}{\partial \sigma_k^2} \right) \\
& = \sum_{d=1}^D \left( \prod_{m=1}^{d-1} \mathcal{N}(x_{nm}|\mu_{km}, \sigma_k^2) \prod_{p=d+1}^D \mathcal{N}(x_{np}|\mu_{kp}, \sigma_k^2) \frac{\partial \left( \frac{1}{\sqrt{2\pi\sigma_k^2}} e^{-\frac{1}{2\sigma_k^2}(x_{nd}-\mu_{kd})^2} \right)}{\partial \sigma_k^2} \right)
\end{aligned}$$

Σχέση (4.1)

Και επίσης το :

$$\begin{aligned}
& \frac{\partial \left( \frac{1}{\sqrt{2\pi\sigma_k^2}} e^{-\frac{1}{2\sigma_k^2}(x_{nd}-\mu_{kd})^2} \right)}{\partial \sigma_k^2} = \frac{\partial \left( \frac{1}{\sqrt{2\pi\sigma_k^2}} \right)}{\partial \sigma_k^2} e^{-\frac{1}{2\sigma_k^2}(x_{nd}-\mu_{kd})^2} + \\
& \frac{\partial \left( e^{-\frac{1}{2\sigma_k^2}(x_{nd}-\mu_{kd})^2} \right)}{\partial \sigma_k^2} \frac{1}{\sqrt{2\pi\sigma_k^2}} = \left( -\frac{1}{2\sqrt{2\pi}(\sigma_k^2)^{\frac{3}{2}}} \right) e^{-\frac{1}{2\sigma_k^2}(x_{nd}-\mu_{kd})^2} +
\end{aligned}$$

$$\begin{aligned}
& \frac{1}{\sqrt{2\pi\sigma_k^2}} e^{-\frac{1}{2\sigma_k^2}(x_{nd}-\mu_{kd})^2} \left( \frac{1}{2}(x_{nd}-\mu_{kd})^2 (\sigma_k^2)^{-2} \right) = \\
& = \left( -\frac{1}{2\sqrt{2\pi\sigma_k^2}} \frac{1}{\sigma_k^2} \right) e^{-\frac{1}{2\sigma_k^2}(x_{nd}-\mu_{kd})^2} + \\
& \frac{1}{\sqrt{2\pi\sigma_k^2}} e^{-\frac{1}{2\sigma_k^2}(x_{nd}-\mu_{kd})^2} \left( \frac{1}{2}(x_{nd}-\mu_{kd})^2 (\sigma_k^2)^{-2} \right) = \\
& = \left( \frac{1}{\sqrt{2\pi\sigma_k^2}} e^{-\frac{1}{2\sigma_k^2}(x_{nd}-\mu_{kd})^2} \right) \left( -\frac{1}{\sigma_k^2} + \frac{1}{2}(x_{nd}-\mu_{kd})^2 (\sigma_k^2)^{-2} \right) =
\end{aligned}$$

$$= \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2) \left( -\frac{1}{\sigma_k^2} + \frac{1}{2} (x_{nd} - \mu_{kd})^2 (\sigma_k^2)^{-2} \right) \quad (4.2)$$

Εφαρμόζοντας την σχέση (4.2) στην σχέση (4.1) τότε έχουμε ότι :

$$\begin{aligned} (4.1) &\xrightarrow{(4.2)} \sum_{d=1}^D \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2) \left( -\frac{1}{\sigma_k^2} + \frac{1}{2} (x_{nd} - \mu_{kd})^2 (\sigma_k^2)^{-2} \right) \prod_{m=1}^{d-1} \mathcal{N}(x_{nm} | \mu_{km}, \sigma_k^2) \prod_{p=d+1}^D \mathcal{N}(x_{np} | \mu_{kp}, \sigma_k^2) = \\ &= \sum_{d=1}^D \prod_{d=1}^D (\mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2)) \left( -\frac{1}{\sigma_k^2} + \frac{1}{2} (x_{nd} - \mu_{kd}^{new})^2 (\sigma_k^2)^{-2} \right) \quad (4.3) \end{aligned}$$

Εφαρμόζοντας την σχέση (4.3) στην (3) και το γεγονός ότι

$$\gamma(z_{nk}) = \frac{\pi_k \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2)}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{jd}, \sigma_j^2)} \text{ τότε καταλήγουμε ότι:}$$

$$\begin{aligned} (3) &\xrightarrow{(4.3)} \sum_{n=1}^N \left( \sum_{d=1}^D \left( \frac{\pi_k \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2)}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{jd}, \sigma_j^2)} \left( -\frac{1}{\sigma_k^2} \right. \right. \right. \\ &\quad \left. \left. \left. + \frac{1}{2} (x_{nd} - \mu_{kd}^{new})^2 (\sigma_k^2)^{-1} (\sigma_k^2)^{-1} \right) \right) \right) = \\ &= \sum_{n=1}^N \sum_{d=1}^D \gamma(z_{nk}) \left( -\frac{1}{\sigma_k^2} \right. \\ &\quad \left. + \frac{1}{2} (x_{nd} - \mu_{kd}^{new})^2 (\sigma_k^2)^{-1} (\sigma_k^2)^{-1} \right) \end{aligned}$$

$$\text{και αφού θέλουμε } \frac{\partial \mathcal{L}(\pi, \mu, \sigma^2)}{\partial \sigma_k^2} = 0 \Rightarrow$$

$$\sum_{n=1}^N \sum_{d=1}^D \gamma(z_{nk}) \left( -\frac{1}{\sigma_k^2} + \frac{1}{2} (x_{nd} - \mu_{kd}^{new})^2 (\sigma_k^2)^{-1} (\sigma_k^2)^{-1} \right) = 0 \Rightarrow$$



$$\begin{aligned}
& \sum_{n=1}^N \sum_{d=1}^D \gamma(z_{nk}) \left( 1 - \frac{1}{2} (x_{nd} - \mu_{kd}^{new})^2 (\sigma_k^2)^{-1} \right) = 0 \Rightarrow \\
& \sum_{n=1}^N \sum_{d=1}^D \gamma(z_{nk}) \left( \sigma_k^2 - \frac{1}{2} (x_{nd} - \mu_{kd}^{new})^2 \right) = 0 \Rightarrow \\
& -\frac{1}{2} \sum_{n=1}^N \sum_{d=1}^D \gamma(z_{nk}) (x_{nd} - \mu_{kd}^{new})^2 = - \sum_{n=1}^N \gamma(z_{nk}) (\sigma_k^2) \Rightarrow \\
& \sum_{n=1}^N \sum_{d=1}^D \gamma(z_{nk}) (x_{nd} - \mu_{kd}^{new})^2 = \sum_{n=1}^N \sum_{d=1}^D \gamma(z_{nk}) (\sigma_k^2) \Rightarrow \\
& \sum_{n=1}^N \sum_{d=1}^D \gamma(z_{nk}) (x_{nd} - \mu_{kd}^{new})^2 = D \sum_{n=1}^N \gamma(z_{nk}) (\sigma_k^2) \Rightarrow \\
& (\sigma_k^2)^{new} = \frac{\sum_{n=1}^N \sum_{d=1}^D \gamma(z_{nk}) (x_{nd} - \mu_{kd}^{new})^2}{D \sum_{n=1}^N \gamma(z_{nk})}
\end{aligned}$$

Όπου αυτός είναι ο τελικός μας τύπος για την ενημέρωση της παραμέτρου  $\sigma_k^2$ .

Τέλος, μεγιστοποιούμε την  $\mathcal{L}(\pi, \mu, \sigma^2)$  ως προς την παράμετρο  $\pi_k$ . Εδώ λαμβάνουμε υπόψιν τον περιορισμό:  $\sum_{k=1}^K \pi_k = 1$  που απαιτεί τους συντελεστής μίξης να αθροίζουν στο ένα. Αυτό ικανοποιείται χρησιμοποιώντας έναν Lagrange πολλαπλασιαστή  $\lambda$  και μεγιστοποιώντας την παρακάτω ποσότητα:

$$\begin{aligned}
\mathcal{L}_{lagrange}(\pi, \mu, \sigma^2) &= \mathcal{L}(\pi, \mu, \sigma^2) + \lambda \left( \sum_{k=1}^K \pi_k - 1 \right) = \\
&= \sum_{n=1}^N \log \sum_{k=1}^K \pi_k \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2) + \lambda \left( \sum_{k=1}^K \pi_k - 1 \right)
\end{aligned}$$

Σχέση (6)

$$\begin{aligned}
\frac{\partial \mathcal{L}_{lagrange}(\pi, \mu, \sigma^2)}{\partial \pi_k} &= \\
&= \left( \sum_{n=1}^N \frac{1}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{jd}, \sigma_j^2)} \frac{\partial (\sum_{k=1}^K \pi_k \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2))}{\partial \pi_k} \right) \\
&+ \lambda \frac{\partial (\sum_{k=1}^K \pi_k - 1)}{\partial \pi_k} = \\
&= \left( \sum_{n=1}^N \frac{\prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2)}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{jd}, \sigma_j^2)} \right) + \lambda
\end{aligned}$$

Και θέλουμε το  $\frac{\partial \mathcal{L}_{lagrange}(\pi, \mu, \sigma^2)}{\partial \pi_k} = 0$  οπότε :

$$\left( \sum_{n=1}^N \frac{\prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2)}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{jd}, \sigma_j^2)} \right) + \lambda = 0 \Rightarrow$$

Πολλαπλασιάζοντας και τα 2 μέλη με το  $\pi_k$  και αθροίζοντας για κάθε  $k$  λαμβάνοντας υπόψιν τον περιορισμό:  $\sum_{k=1}^K \pi_k = 1$  βρίσκουμε ότι  $\lambda = -N$  καθώς  $\sum_{k=1}^K \pi_k \lambda = -\sum_{k=1}^K \sum_{n=1}^N \gamma(z_{nk})$  όπου  $\sum_{k=1}^K \sum_{n=1}^N \gamma(z_{nk}) = N$  άρα  $\lambda = -N$ .

Χρησιμοποιούμε αυτό για να εξαλείψουμε το  $\lambda$  και το γεγονός ότι

$$\gamma(z_{nk}) = \frac{\pi_k \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2)}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{jd}, \sigma_j^2)} \text{ τότε καταλήγουμε ότι:}$$

$$\left( \sum_{n=1}^N \frac{\pi_k \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2)}{\sum_{j=1}^K \pi_j \prod_{d=1}^D \mathcal{N}(x_{nd} | \mu_{jd}, \sigma_j^2)} \right) + \lambda \pi_k = 0 \Rightarrow$$

$$\left( \sum_{n=1}^N \gamma(z_{nk}) \right) + \lambda \pi_k = 0 \Rightarrow$$

$$\left( \sum_{n=1}^N \gamma(z_{nk}) \right) = -\lambda \pi_k \xrightarrow{\lambda = -N}$$

$$\frac{\sum_{n=1}^N \gamma(z_{nk})}{N} = \pi_k$$

Τα ίδια αποτελέσματα θα είχαμε άμα είχαμε πάρει την expected λογαριθμική complete πιθανοφάνεια για να αποδείξουμε τους παραπάνω τύπους, δηλαδή την :

$$Q(\theta, \theta^{(t)}) = \sum_{k=1}^K \left( \sum_{n=1}^N \gamma(z_{nk}) \right) \log \pi_k + \sum_{k=1}^K \left( \sum_{n=1}^N \gamma(z_{nk}) \sum_{d=1}^D \log \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \Sigma_k) \right)$$

### **LOGSUMEXP TRICK**

Για να έχουμε ευσταθείς αριθμητικούς υπολογισμούς στην εργασία μας χρησιμοποιήσαμε το logsumexp trick. Όπου το  $\gamma(z_{nk})$  γίνεται ίσο με:

$$\gamma(z_{nk}) = \frac{e^{f_k - m}}{\sum_{j=1}^K e^{f_j - m}}$$

Όπου  $f_k = e^{\log \pi_k + \sum_{d=1}^D \log \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2)}$

Όπου  $\log \mathcal{N}(x_{nd} | \mu_{kd}, \sigma_k^2) = -\frac{1}{2} \log(2\pi\sigma_k^2) - \frac{1}{2\sigma_k^2} (x_d - \mu_{kd})^2$

Και  $m = \max(f_1, f_2, \dots, f_K)$

Επίσης, χρησιμοποιούμε logsumexp trick και για τον υπολογισμό της λογαριθμικής πιθανοφάνειας η οποία γίνεται :

$$\mathcal{L}(\pi, \mu, \sigma^2) = \sum_{n=1}^N m + \log \sum_{k=1}^K e^{f_k - m}$$


## ΠΑΡΑΔΕΙΓΜΑΤΑ ΥΛΟΠΟΙΗΣΗΣ ΕΜ

Υλοποιούμε τον ΕΜ για  $K=[1,2,4,8,16,32]$  (όπου  $K$  είναι ο αριθμός των ομάδων) και πάνω στην εξής φωτογραφία που βρίσκεται στον φάκελο Image στο παραδοτέο project.




--Αρχική φωτογραφία--

Για αριθμό ομάδων(K) ίσο με 1 έχουμε το ακόλουθο αποτέλεσμα:




```
--Cluster: 1-----  
Iteration: 1  
Iteration: 2  
Convergence criterion is met  
Total iterations: 2  
Time of execution of EM for cluster(k) = 1 is 0.6706511974334717 seconds  
Error of reconstruction: 0.029689080812792795
```

Για αριθμό ομάδων(K) ίσο με 2 έχουμε το ακόλουθο αποτέλεσμα:



```
Convergence criterion is met  
Total iterations: 30  
Time of execution of EM for cluster(k) = 2 is 17.1512451171875 seconds  
Error of reconstruction: 0.026437034988610133
```


Για αριθμό ομάδων( $K$ ) ίσο με 4 έχουμε το ακόλουθο αποτέλεσμα:



```
Convergence criterion is met  
Total iterations: 210  
Time of execution of EM for cluster(k) = 4 is 242.62264442443848 seconds  
Error of reconstruction: 0.022027688591410143
```



Για αριθμό ομάδων(K) ίσο με 8 έχουμε το ακόλουθο αποτέλεσμα:



```
Convergence criterion is met  
Total iterations: 251  
Time of execution of EM for cluster(k) = 8 is 549.7296178340912 seconds  
Error of reconstruction: 0.019438892701334174
```



Για αριθμό ομάδων( $K$ ) ίσο με 16 έχουμε το ακόλουθο αποτέλεσμα:



```
Time of execution of EM for cluster(k) = 16 is 2147.7413337230682 seconds  
Error of reconstruction: 0.0159829307941458
```

Για αριθμό ομάδων( $K$ ) ίσο με 32 έχουμε το ακόλουθο αποτέλεσμα:



```
Time of execution of EM for cluster(k) = 32 is 4517.353576421738 seconds  
Error of reconstruction: 0.013109559654380818
```

Για αριθμό ομάδων(K) ίσο με 64 έχουμε το ακόλουθο αποτέλεσμα:



```
Time of execution of EM for cluster(k) = 64 is 8567.164550304413 seconds  
Error of reconstruction: 0.010639547133201652
```